

BÁO CÁO BÀI TẬP: XÂY DỰNG MẠNG NƠ-RON ĐA LỚP (MLP)

Môn học: Học máy và Khai phá dữ liệu

Chủ đề: Phân loại tập dữ liệu Student Performance

Họ và tên: Trần Quang Khải

Mã sinh viên: BIT230207

1. GIỚI THIỆU BÀI TOÁN VÀ DỮ LIỆU

1.1. Mục tiêu bài toán

Mục tiêu cốt lõi của bài tập này là nghiên cứu và xây dựng cấu trúc mạng nơ-ron nhân tạo đa lớp (Multi-Layer Perceptron - MLP) hoàn toàn từ đầu (from scratch) mà không phụ thuộc vào bất kỳ thư viện học máy cao cấp nào sẵn có (như scikit-learn, TensorFlow hay PyTorch). Hệ thống được triển khai bằng ngôn ngữ Python dựa trên các phép toán ma trận cơ bản của thư viện Numpy và cấu trúc dữ liệu của Pandas. Mô hình được ứng dụng cụ thể để thực hiện phân lớp dữ liệu, nhằm mục đích dự đoán kết quả học tập cuối kỳ của sinh viên dựa trên các đặc trưng về thông tin cá nhân, thói quen sinh hoạt, giáo dục và hoàn cảnh gia đình.

1.2. Mô tả tập dữ liệu (Student Performance Dataset)

Bộ dữ liệu sử dụng trong thực nghiệm được thu thập từ sinh viên vào năm 2019. Cấu trúc và đặc điểm của tập dữ liệu bao gồm:

- Quy mô dữ liệu:** Tổng cộng có 145 mẫu dữ liệu tương ứng với 145 sinh viên được khảo sát.
- Các đặc trưng đầu vào (Features):** Bao gồm 31 đặc trưng (từ cột 1 đến cột 31). Trong đó, các cột từ 1 đến 10 tập trung vào câu hỏi thông tin cá nhân (tuổi, giới tính, học bổng, việc làm thêm); các cột từ 11 đến 16 bao gồm các thông tin chi tiết về gia đình (trình độ giáo dục và nghề nghiệp của cha mẹ, số lượng anh chị em); các cột còn lại phản ánh thói quen giáo dục và học tập cá nhân (số giờ tự học, tần suất đọc sách, phương pháp chuẩn bị cho các kỳ thi, mức độ tương tác và thảo luận trên lớp).
- Nhãn mục tiêu đầu ra (Output Grade):** Nằm ở cột thứ 32 (GRADE), phân loại kết quả học tập thành 8 mức nhãn rời rạc tương ứng với thang điểm chữ: 0: Fail, 1: DD, 2: DC, 3: CC, 4: CB, 5: BB, 6: BA, 7: AA.
- Đặc điểm phân bố:** Tập dữ liệu có đặc tính mất cân bằng tương đối lớn giữa các lớp nhãn (ví dụ: lớp 1 - DD chiếm đa số với hơn 35 mẫu, trong khi lớp nhãn thấp nhất như lớp 0 - Fail chỉ có 8 mẫu), gây ra thử thách đáng kể cho quá trình huấn luyện và tối ưu hóa tham số mạng.

1.3. Tiền xử lý dữ liệu (Data Preprocessing)

Trước khi đưa vào mạng nơ-ron huấn luyện, dữ liệu thô bắt buộc phải trải qua quy trình tiền xử lý nghiêm ngặt nhằm đảm bảo tính ổn định và tăng tốc độ hội tụ của thuật toán:

- **Mã hóa danh mục (Label Encoding):** Kiểm tra và thực hiện chuyển đổi các biến định tính hoặc chuỗi văn bản (Categorical variables) thành dạng số nguyên rời rạc theo thứ tự logic. Bộ dữ liệu khảo sát này đảm bảo tính toàn vẹn và không chứa các giá trị bị khuyết (Missing Values).
- **Chuẩn hóa Min-Max (Min-Max Scaling):** Để triệt tiêu sự chênh lệch về biên độ giá trị giữa các thuộc tính (gây ra hiện tượng mất cân bằng trọng số khi tính toán Gradient), toàn bộ 31 đặc trưng đầu vào được chuẩn hóa tuyến tính về khoảng không gian $[0, 1]$ theo công thức toán học:

$$X_{scaled} = (X - X_{min}) / (X_{max} - X_{min})$$

- **Mã hóa One-Hot (One-Hot Encoding):** Nhãn đầu ra GRADE chứa các giá trị số nguyên từ 0 đến 7 được chuyển đổi toàn vẹn sang dạng ma trận vector nhị phân 8 chiều (ví dụ: nhãn 2 biến đổi thành vector $[0, 0, 1, 0, 0, 0, 0, 0]$). Bước xử lý này tương thích trực tiếp với hàm phân phối xác suất Softmax tại tầng đầu ra của mạng.

2. CƠ SỞ LÝ THUYẾT VÀ KIẾN TRÚC MÔ HÌNH

Mô hình thực nghiệm được xây dựng theo kiến trúc mạng MLP truyền thẳng chuẩn bao gồm: 01 Lớp đầu vào (Input Layer), 01 Lớp ẩn (Hidden Layer) và 01 Lớp đầu ra (Output Layer). Luồng xử lý và biến đổi thông tin tuần tự qua cấu trúc:

Input Layer (31 nơ-ron) → Hidden Layer (N nơ-ron) → Output Layer (8 nơ-ron)

2.1. Các hàm kích hoạt và giải pháp chống tràn số (Overflow)

a) Lớp ẩn (Hàm kích hoạt Sigmoid):

Hàm Sigmoid nhận nhiệm vụ ánh xạ các giá trị tổ hợp tuyến tính từ lớp đầu vào về khoảng phi tuyến $(0, 1)$:

$$a = \sigma(z) = 1 / (1 + e^{-z})$$

Giải pháp ổn định số học: Trong môi trường lập trình số thực dấu phẩy động (float64), nếu giá trị z mang dấu âm lớn, thành phần e^{-z} sẽ tăng tiến cực đại vượt ngưỡng lưu trữ dẫn đến lỗi tràn số (overflow). Thuật toán được tinh chỉnh chia thành hai trường hợp xử lý:

- Với $z \geq 0$: Sử dụng công thức gốc $\sigma(z) = 1 / (1 + e^{-z})$
- Với $z < 0$: Biến đổi toán học tương đương thành $\sigma(z) = e^z / (1 + e^z)$

b) Lớp đầu ra (Hàm kích hoạt Softmax):

Để giải quyết bài toán phân loại đa lớp, lớp đầu ra sử dụng hàm Softmax để chuyển đổi các giá trị thô thành một phân phối xác suất chuẩn hóa trên tổng số 8 lớp nhãn:

$$\hat{y}_i = \text{softmax}(z_i) = e^{z_i} / \sum_{j=1}^K e^{z_j}$$

Giải pháp ổn định số học: Nhằm ngăn chặn hiện tượng tràn số khi thực hiện hàm mũ với các giá trị z_i dương quá lớn, toàn bộ vector đầu vào lớp ra được trừ đi giá trị cực đại của chính nó trước khi đưa vào hàm tính toán:

$$\hat{y}_i = e^{z_i - \max(z)} / \sum_{j=1}^K e^{z_j - \max(z)}$$

2.2. Hàm mất mát Cross-Entropy (Loss Function)

Độ lỗi giữa phân phối xác suất dự đoán của mô hình và vector nhãn One-hot thực tế được đo lường thông qua hàm mất mát Cross-Entropy toàn cục:

$$L = - (1 / N) \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(\hat{y}_{ik})$$


Nhằm loại bỏ hoàn toàn rủi ro xuất hiện lỗi vô định toán học $\log(0)$ khi giá trị dự đoán tiến sát về mức 0, một hằng số bổ trợ siêu nhỏ $\epsilon = 10^{-12}$ đã được tích hợp trực tiếp vào biểu thức xử lý: $\log(\hat{y}_{ik} + \epsilon)$.

3. THIẾT LẬP KỊCH BẢN VÀ KẾT QUẢ THỰC NGHIỆM


Hệ thống ma trận trọng số của mạng được khởi tạo ngẫu nhiên theo phân phối Uniform dựa trên phương pháp tối ưu **Xavier/Glorot** với hạt giống ngẫu nhiên được cố định tuyệt đối (`seed = 42`) để đảm bảo tính tái lập kết quả. Quá trình huấn luyện sử dụng thuật toán hạ dốc gradient tiêu chuẩn (Gradient Descent) kết hợp điều kiện dừng sớm (Early Stopping) dựa trên ngưỡng mất mát đặt trước.

Dưới đây là bảng tổng hợp so sánh chi tiết các tham số vận hành hệ thống qua 3 kịch bản thực nghiệm cấu hình:

Kịch bản Thử nghiệm	Kiến trúc Mạng (Nơ-ron)	Tốc độ học (LR)	Vòng lặp Tối đa	Ngưỡng Dừng Sớm	Số Vòng lặp Thực tế	Thời gian Chạy (s)	Giá trị Loss cuối	Độ chính xác (%)
Kịch bản 1 (Nhỏ)	31 → 16 → 8	0.05	1000	0.0001	1000 (Max)	0.0904	1.817835	30.34%
Kịch bản 2 (Vừa)	31 → 32 → 8	0.10	2000	0.0001	2000 (Max)	0.2931	1.173652	60.69%
Kịch bản 3 (Lớn)	31 → 64 → 8	0.20	3000	1.0000	1279 (Early)	0.3358	0.999914	64.83%



Hình 1: Biểu đồ đường cong hàm mất mát (Loss Curve) qua các epoch của 3 kịch bản



Hình 2: Biểu đồ theo dõi độ chính xác (Accuracy Curve) qua các epoch của 3 kịch bản

4. PHÂN TÍCH VÀ ĐÁNH GIÁ THỰC NGHIỆM

4.1. Tác động của Số lượng nơ-ron lớp ẩn (Hidden Capacity)

Số lượng nơ-ron tại lớp ẩn đại diện cho không gian và năng lực biểu diễn phi tuyến của mô hình. Ở Kịch bản 1 với quy mô 16 nơ-ron, cấu trúc mạng quá đơn giản dẫn tới hiện tượng Underfitting, mạng không thể phân tách các biên quyết định phức tạp từ 31 đặc trưng đầu vào, thể hiện qua độ chính xác rất thấp (30.34%). Khi thực hiện mở rộng quy mô lên 32 nơ-ron (KB2) và 64 nơ-ron (KB3), không gian biểu diễn được tối ưu đáng kể, giúp độ chính xác kiểm thử tăng vọt và đạt đỉnh ở mức 64.83%. Điều này chứng minh quy mô 64 nơ-ron lớp ẩn là điểm cân bằng phù hợp đối với cấu trúc dữ liệu Student Performance. Qua biểu đồ Accuracy Curve (Hình 2), có thể thấy quỹ đạo học tập của Kịch bản 3 (màu xanh lá) vươn lên nhanh và ổn định nhất.

4.2. Tác động của Tốc độ học (Learning Rate - LR)

Tốc độ học điều tiết bước đi của thuật toán trên bề mặt tối ưu gradient. Định cấu hình tốc độ học thấp ở mức 0.05 (KB1) khiến tiến trình cập nhật tham số diễn ra chậm chạp, hệ thống mất rất nhiều vòng lặp nhưng vẫn bị kẹt ở vùng có giá trị hàm lỗi cao (Loss = 1.8178), thể hiện rõ qua đường cong Loss Curve thoải và chậm giảm (Hình 1). Ngược lại, việc tăng cường tốc độ học lên mức 0.20 (KB3) kết hợp hài hòa với hàm kích hoạt Sigmoid giúp đẩy nhanh tốc độ hội tụ của mạng, đường cong Loss dốc xuống mạnh mẽ giúp các vector trọng số nhanh chóng tìm được điểm cực tiểu cục bộ tốt mà không xảy ra hiện tượng phân kỳ hay dao động mất kiểm soát.

4.3. Hiệu quả của Cơ chế Dừng sớm (Early Stopping)

Cơ chế dừng sớm thể hiện giá trị vận hành tối ưu rõ rệt trong cấu hình Kịch bản 3. Khi thiết lập ngưỡng stop_loss = 1.0000, thuật toán lan truyền ngược tự động ngắt tiến trình tại vòng lặp thứ 1279 ngay khi điều kiện được đáp ứng, đường Loss (Hình 1) kết thúc sớm thay vì tiếp tục thực thi lãng phí toàn bộ 3000 vòng lặp theo kế hoạch định sẵn. Giải pháp này mang lại hai lợi ích lớn: vừa tiết kiệm gần 60% tổng chi phí tài nguyên và thời gian tính toán của CPU, vừa đóng vai trò như một bộ tinh chỉnh kiểm soát, ngăn chặn tình trạng mạng nơ-ron học vẹt (Overfitting) trên tập dữ liệu mẫu nhỏ (145 dòng), giữ vững năng lực tổng quát hóa.

5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Nghiên cứu đã hoàn thành toàn vẹn việc thiết kế, xây dựng và tối ưu hóa mô hình mạng nơ-ron nhân tạo đa lớp MLP hoàn toàn từ mã nguồn gốc cơ bản. Việc ứng dụng linh hoạt các giải pháp kỹ thuật như chuẩn hóa Min-Max, mã hóa One-Hot kết hợp kiến trúc chống tràn số cho hàm Sigmoid/Softmax đã giúp hệ thống vận hành đạt độ ổn định toán học tuyệt đối. Thuật toán Lan truyền ngược (Backpropagation) hoạt động chính xác, giúp mô hình đạt hiệu năng nhận diện phân lớp tối ưu ở mức 64.83% độ chính xác.

5.2. Hướng phát triển nhằm nâng cao chất lượng mô hình

Do giới hạn đặc thù của bộ dữ liệu Student Performance (kích thước mẫu nhỏ và có độ lệch phân bố nhãn cao), để phát triển mô hình đạt độ chính xác cao và đáng tin cậy hơn nữa, các giải pháp công nghệ sau được đề xuất triển khai:

- **Áp dụng Stratified K-Fold Cross Validation:** Thay thế việc đánh giá trên một tập dữ liệu cố định bằng phương pháp chia cụm kiểm chứng chéo K-Fold giữ nguyên tỷ lệ phân bố lớp nhãn, giúp thu được chỉ số đánh giá khách quan và chính xác hơn về năng lực tổng quát hóa của mô hình.
- **Tích hợp Kỹ thuật Regularization (L2 Regularization / Dropout):** Áp dụng cơ chế Weight Decay (L2) để phạt các trọng số có giá trị quá lớn hoặc bổ sung lớp Dropout tại tầng ẩn, giảm thiểu triệt để xu hướng Overfitting khi mở rộng mạng lên số lượng nơ-ron lớn hơn.
- **Nâng cấp Thuật toán Tối ưu (Adam Optimizer & Mini-batch):** Thay thế phương pháp Batch Gradient Descent hiện tại bằng thuật toán tối ưu Adam kết hợp huấn luyện theo từng cụm dữ liệu nhỏ (Mini-batch Gradient Descent). Sự cải tiến này sẽ giúp mô hình tăng tốc thời gian huấn luyện mạnh mẽ, đồng thời bổ sung khả năng thoát khỏi các điểm cực tiểu cục bộ (local minima) một cách hiệu quả.